随机过程大作业：高斯过程回归与股票预测

1. 模型定义

1.1 概述

高斯过程回归（Gaussian Process Regression，GPR）是一种基于贝叶斯理论的非参数化模型，其核心思想是利用随机过程特性对目标函数进行建模。与传统的参数化模型（如线性回归、多项式回归等）预先设定函数的形式不同，高斯过程将目标函数视为一个随机过程，对样本数据的先验分布进行相关性假设，以核函数和协方差矩阵为核心、利用样本点修正假设、推导得到后验分布，再用后验分布预测未知点的函数值。

在金融时间序列预测中，股票价格具有显著的波动性和噪声特征，GPR 不仅能提供准确的均值预测，还能通过协方差矩阵量化预测结果的不确定性（即给出预测值的置信区间），这种概率性的输出使得高斯过程在风险管理和股价趋势预测中具有独特的数学优势。

另一方面，GPR 训练阶段的时间复杂度为 $O(n^3)$（即通过 Cholesky 分解求协方差矩阵的逆的时间复杂度）、预测阶段的时间复杂度为 $O(n^2)$，空间复杂度为 $O(n^2)$，因此适合小样本或需要量化预测不确定度的场景，当样本量较大时计算负荷非常高。同时，GPR 的性能较大依赖于核函数与其超参数的选择。

1.2 模型的数学刻画

假设目标函数满足高斯过程先验：

$$f(x) \sim \mathcal{GP}(m(x), k(x, x'))$$

常见简化取 $m(x) \equiv 0$，此时函数间的关联完全由核函数 k 描述。

观测值用带高斯噪声的模型表示：

$$y_i = f(x_i) + \varepsilon_i, \varepsilon_i \sim \mathcal{N}(0, \sigma_n^2)$$

为简化实现，可以将观测噪声并入协方差函数，等价地把噪声项写成 $\sigma_n^2 \delta_{ij}$加到协方差矩阵的对角线上。

对训练集 $\mathcal{D} = \{X = \{x_i\}_{i=1}^n, y\}$ 构造协方差矩阵 K：

$$K_{ij} = k(x_i, x_j) + \sigma_n^2 \delta_{ij}$$

给定训练数据，对于待预测的新输入 X_*，记 $K_* = k(X, X_*), K_{**} = k(X_*, X_*)$。可基于条件高斯分布的结论，写出其分布的均值与协方差：

$$\begin{aligned} \mathbb{E}[f_*] &= K_*^\top K^{-1} y, \\ \mathrm{Cov}[f_*] &= K_{**} - K_*^\top K^{-1} K_*. \end{aligned}$$

在数值实现中，为保证数值稳定与效率，通常通过 Cholesky 分解 $K = LL^\top$ 来替代直

接求矩阵的逆。

1.3 超参数选择

核函数 k 通常由一组超参数 θ（如尺度、长度尺度、噪声方差等）决定。超参数的常用估计方法是最大化观测数据的对数边际似然（log marginal likelihood）：

$$\log\ p(y \mid X, \theta) = -\frac{1}{2} y^{\top} K^{-1} y - \frac{1}{2} \log|K| - \frac{n}{2} \log\ 2\pi$$

其中，$-\frac{1}{2} y^{\top} K^{-1} y$ 为数据拟合项，基于 K 描述样本点之间相关性的性质，衡量模型对当前训练数据的解释能力；$-\frac{1}{2}\log|K|$ 为复杂度惩罚项，防止模型过于复杂、发生过拟合。

K 隐含依赖于 θ。通过梯度下降等方法对该式进行数值优化可以得到经验上的“最优”超参数。

1.4 核函数选择

核函数 k 有多重选择，这里列出常用的几种、以及 GPR 股票预测相关论文中提及的一些核函数：

（1）平方指数核（RBF / Squared Exponential Kerne，SE）

常用选择，用于建模平滑变化。

$$k_{\mathrm{SE}}(d) = \sigma_f^2 \exp\left(-\frac{d^2}{2l^2}\right), d = |x - x'|$$

其中，信号方差 σ_f^2 控制函数在垂直方向上的波动幅度，长度尺度 l 控制相关的距离。

（2）周期核（Periodic Kernel / Exponential Sine Squared Kernel）

用于建模具有重复循环模式的数据，例如股市预测中的“季节性效应”、“周内效应”或“财报周期”等规律。

$$k_{ESS}(d) = \exp\left(-\frac{2sin^2(\pi d/p)}{l^2}\right), d = |x - x'|$$

其中，p 为周期参数，l 为长度尺度

（3）白噪声核（White Kernel）

用于识别噪声，提高预测的泛化能力。

$$k(x, x') = \sigma_n^2 \delta_{x,x'}$$

其中，σ_n^2 表示测量误差或不可预测的随机波动水平。

（4）Matern 核

在[3]中被提及，用于改进 SE 核过于平滑的缺点、捕捉股票的小幅震荡特征。

$$k_{3/2}(d) = \sigma_f^2\left(1+\frac{\sqrt{3}d}{l}\right)\exp\left(-\frac{\sqrt{3}d}{l}\right), d = |x - x'|$$

其中，l 为长度尺度。

（5）有理二次核 (Rational Quadratic，RQ)

同样在[3]中被提及，可以看作无限多个具有不同长度尺度的 SE 核的叠加，适合建模“多尺度”（即同时存在短期波动、中期调整和长期趋势的复杂市场）的股市变化。

$$k_{RQ}(d) = \sigma_f^2\left(1+\frac{d^2}{2\alpha l^2}\right)^{-\alpha}, d = |x - x'|$$

其中，α 控制不同长度尺度的混合程度，如果 α 非常大，则该函数退化为 SE 核；l 为长度尺度。

本次作业中，使用基本的 SE、ESS、White Kernel，通过相加组合构成核函数，预测股票趋势。这种组合易于搭建，且实现了加法分解：SE 核锁定长期上涨或下跌的大趋势；ESS 核捕捉如“周内效应”等重复性规律；White Kernel 吸收随机波动，显著增强数值稳定性。该方案既能过滤市场噪声避免过拟合，又能提供具备多尺度特征的置信区间，使趋势预测更具逻辑性和风险参考价值。具体的模型搭建在 2.3 中给出。

2. GPR 在股票预测场景的应用实现

2.1 实验概述

本实验实现以 sklearn 的 GaussianProcessRegressor 为核心，使用历史年度的收盘价构建训练集，对指定的测试年份进行 GPR 预测，并给出不确定度预测（均值 + 方差 +95% 置信区间）。训练时，使用多年度股票数据作为训练集，单年度作为测试集；评估使用 RMSE、MAE 与 R^2。总体的训练过程参考了[4]中的实验方法，具体的代码在附件中给出。

实验使用的股票数据集均来源于 Nasdaq，包含 MSTF、NTDOF、NVDA、SEGA、SONY 共 5 家公司的近 10 年历史股票数据。每个公司的股票数据记录了该股票每日的开盘价、收盘价、最高价、最低价、成交量等信息，数据时间跨度为 2015 年 12 月 21 日至 2025 年 12 月 19 日。训练时，训练集为 2016 年至 2024 年的全季度股票数据，测试集为 2025 年的全季度股票数据。

以下是五支股票的原始数据折线图：

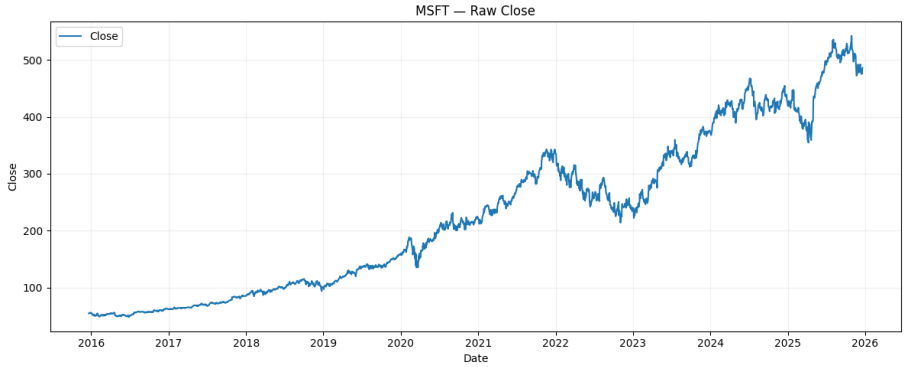
MSFT — Raw Close
Close
Close
Date

NTDOF — Raw Close
Close
Close
Date

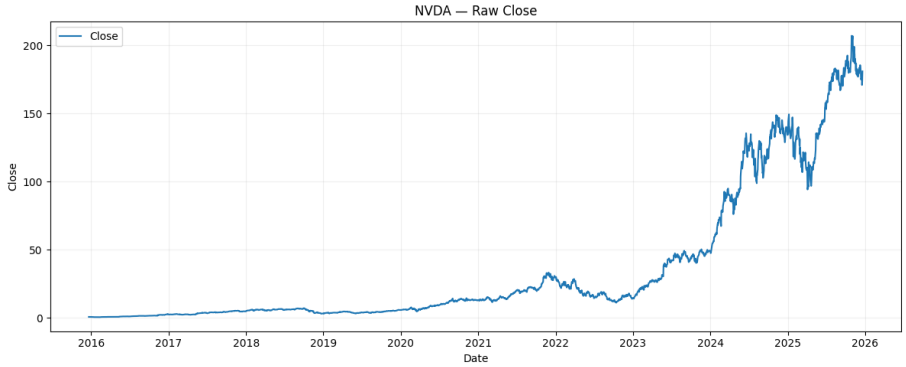
NVDA — Raw Close
Close
Close
Date

SEGA — Raw Close
Close
Close
Date

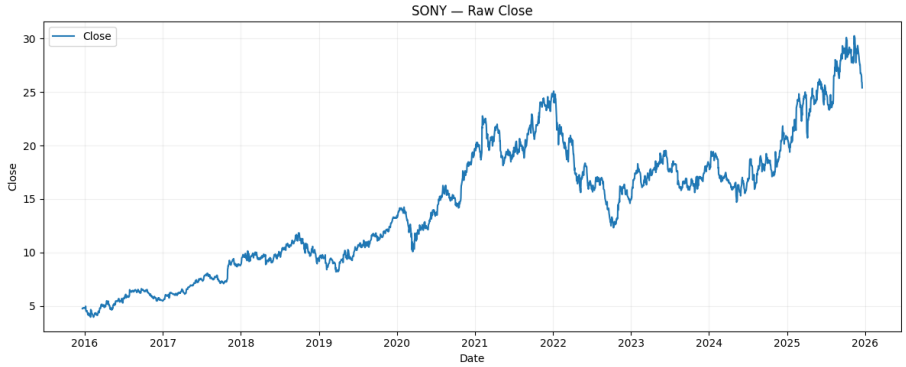

从图中可以看出各支股票数据集的特点：

（1）MSFT 和 SONY 呈现出典型的长期上升趋势。波动相对平滑，虽然在 2022 年左右受加息影响、有明显的回调，但整体逻辑连贯，具有较强的非平稳性。实验中，可作为基准测试，用于验证 GPR 捕捉长期趋势的能力。

（2）NVDA 呈现指数级爆发型增长，特别是 2023 年以后，受 AI 热点驱动、股价出现了极其陡峭的斜率。这种数据具有极高的方差不稳定性。实验中，可以用于测试模型对高梯度变化和异方差性的适应力，评估核函数的平滑特性造成的预测失效风险。

（3）NTDOF 在 2022 年末发生拆股，导致原始股价突变、出现了巨大的断崖式下跌。实验中，可以利用这一数据集测试模型对结构性变化或突发事件的鲁棒性；然而，由于实际的总股价不变，因此实际预测时，需要改用复权价格进行预测。

（4）SEGA 呈现出明显的阶梯状分布，且存在频繁的局部震荡，这是由于其市值较小、且交易逻辑受具体产品周期影响较大所导致。实验中，可用于测试模型的抗噪能力。

2.2 数据预处理

按以下步骤，对每支股票的原始数据进行预处理。

（1）读取原始数据。从 CSV 中读取数据，保留 Date 与 Close 两列；将 Date 解析为 datetime，去除 Close 字段中的美元符号和千位分隔符并转换为浮点，丢弃缺失条目、按时间升序排序。

（2）按年对齐数据。同一自然年内，每日收盘价提取为一列、不同年份对应不同列，形成按年对齐的矩阵。处理后的表格中，每一列代表一年，行索引为交易日序号，便于按年比较与交叉训练。

（3）数据标准化。对每一列（某一年的数据）分别计算均值与标准差，用该列的均值 / 标准差将当年价格标准化为零均值、单位方差，以去除不同年份的尺度差异，便于跨年建模；每年的数据，减去当年的第一个数据、使偏置为 0，从而减少基线偏移（价格绝对值）的影响，提高模型对变化模式的敏感度。

（4）填充与截断。为保证每列长度一致，采用 MAX_DAYS=252 作为行数上限；若某列样本少于该长度，则对尾部的缺失值使用该列均值填充；同时，额外构造季度

（Quarter）列（按四分之一切分行索引），用于可视化时标注季度边界。

（5）构造训练集和测试集。输入特征由两维组成：[year_offset, day_index]，其中 year_offset = year - primary_year（用最小训练年份作基准 primary_year 以缩小年份数值范围），day_index 为当年中的天序号（0～MAX_DAYS-1）；目标变量为对应位置的标准化收盘价。测试集由指定的测试年份（2025）对应列中的样本组成，训练集由所选训练年份（2016～2024）的所有样本组成。

完成预处理，得到标准化、按年对齐、包含季度列的 DataFrame 数据，作为后续模型输入与测试基准。

以下是预处理后，各支股票的历史数据折线图（仅包含训练集）：

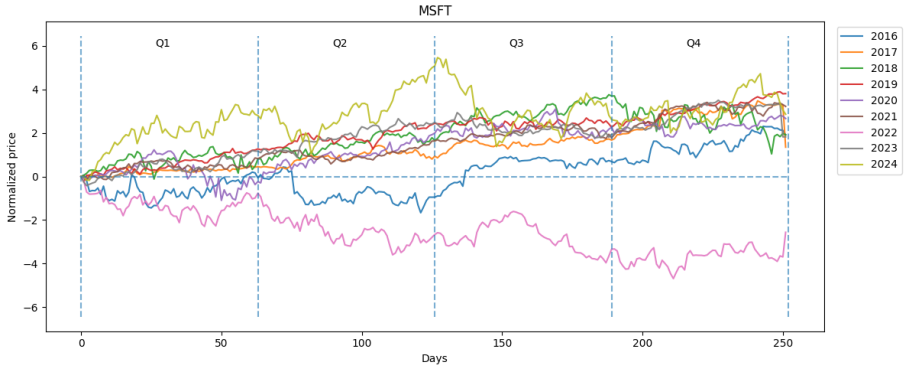

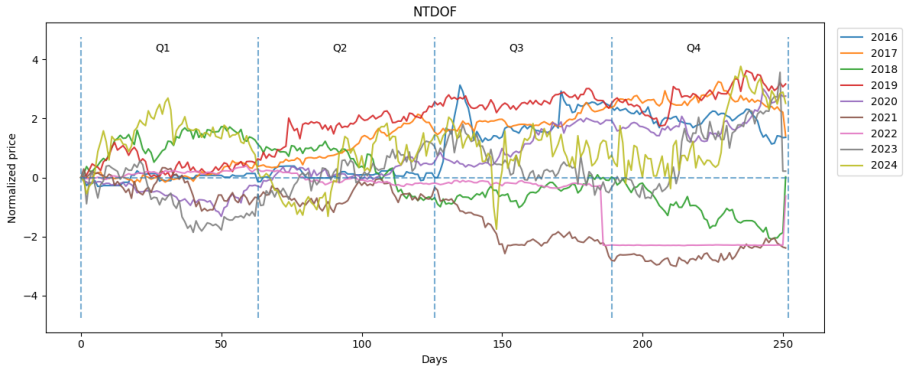

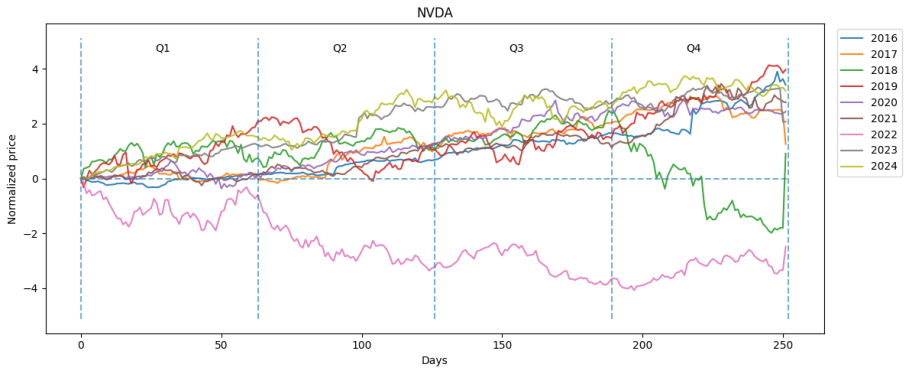

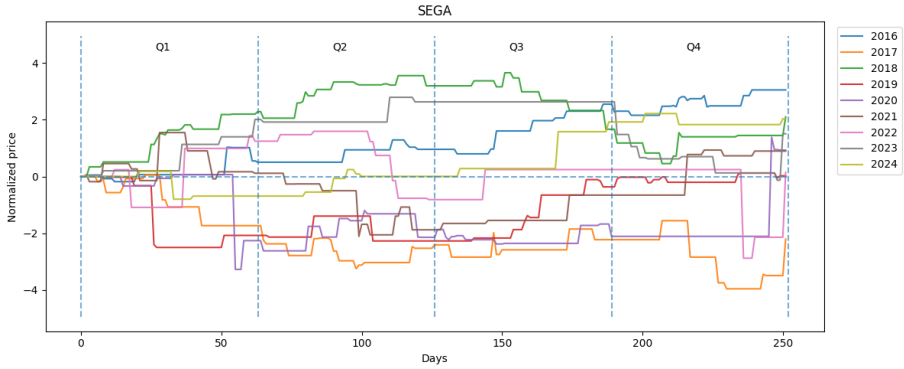

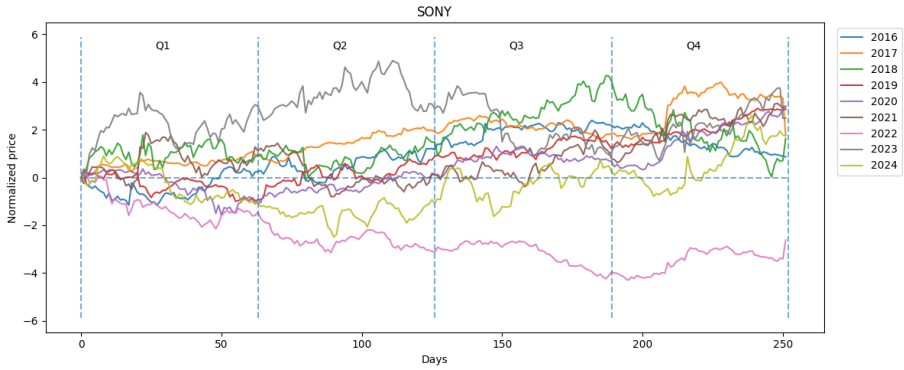

2.3 模型搭建

使用 sklearn 的 GaussianProcessRegressor 搭建 GPR 模型。模型学习的是归一化后的价格变化规律，因此所有预测与误差均以标准化刻度表示。

（1）核函数设计

为同时捕捉长期平滑趋势、年内周期性以及观测噪声，采用复合核刻画先验分布，具体由以下核函数构成：

① RBF 核，用于描述平滑的长期趋势。初始化参数中，平滑尺度 length_scale=10、边界为 (1e-2, 1e3)，保证模型起点稳定、既不过度平滑也不过度波动。

② ExpSineSquared 周期核，用于描述年内或季节性的周期振荡。初始化参数中，周期 periodicity=252、将“交易日一年约 252 天”的先验知识引入模型，期望 GPR 快速捕捉年内季节性或年周期性的模式；length_scale=50，既能保留明显周期、又不过分强调短期相位差异；periodicity 边界为 (50,400)，允许学出比 252 更短的周期性特征（如季节性）或更长的周期，但避免退化到完全任意周期性。

③ WhiteKernel 白噪声核，用于建模观测噪声。初值为 1e-3、边界为 (1e-6, 1e-1)，保证合理范围内的噪声刻画。

初始化核函数时，上述分量以常数系数加权，权重为 63.0 * RBF + 17.0 * ExpSineSquared + White，表示先验上认为平滑趋势在总方差中占主要部分，周期分量贡献较小、但不能忽略。这些初值为优化器提供合理起点，具体权重及核参数由训练时的内置优化器进一步调整。

（2）GPR 配置

对 GaussianProcessRegressor 设置超参数：alpha=1e-6，用于增加数值稳定性、轻微抑制过拟合；normalize_y=True，对预测目标标准化、使其满足分布均值为 0 的先验假设；n_restarts_optimizer=50，以多次随机重启优化内核超参、减小陷入局部最优的风险。该配置在平衡表达能力与稳定性之间做出折中。

具体的模型搭建代码如下。

```
# 搭建模型
# kernel: 趋势 + 周期 + 噪声
rbf_kernel = RBF(length_scale=10.0, length_scale_bounds=(1e-2, 1e3))
exp_kernel = ExpSineSquared(
    length_scale=50.0, periodicity=252,
    length_scale_bounds=(1e-2, 1e3), periodicity_bounds=(50, 400)
)
white_kernel = WhiteKernel(noise_level=1e-3, noise_level_bounds=(1e-6, 1e-1))
kernel = 63.0 * rbf_kernel + 17.0 * exp_kernel + white_kernel

gp = GaussianProcessRegressor(
    kernel=kernel, alpha=1e-6,
    normalize_y=True,
    n_restarts_optimizer=n_restarts
)
```

2.4 模型训练与测试

（1）训练。将上文构造的训练集输入 GPR，调用拟合接口完成超参数优化，并输出学习后的核函数。

（2）预测与可视化。对测试年份，在连续日索引上构造高分辨率网格，对该密集网格进行预测并请求返回协方差矩阵，从而计算点处标准差，并绘制均值曲线及 95% CI 置信带。同时，对测试集的实际观测点计算模型预测值，以供定量评估。

（3）定量评估指标。对测试样本计算回归指标，包括均方根误差（RMSE）、平均绝对误差（MAE）与判定系数（R^2）。这些指标用于衡量模型在测试年份已观测日点上的拟合与预测误差。

（4）预测结果可视化。基于测试集和网格预测的结果，绘制测试集分布、预测均值曲线与 95%置信带，以便直观地查看预测与不确定度随年内时间的变化。

具体的训练结果核函数、测试结果以及模型评估见第 3 部分“结果评估”。

3. 结果评估

3.1 预测性能的定量评估

基于测试集上的三项标准回归指标（均方根误差（RMSE）、平均绝对误差（MAE）和判定系数（R^2 ）），对五支股票的预测性能做定量比较。以下指标值均在标准化后的尺度下计算得出。

股票名称	RMSE	MAE	R^2
MSFT	1.2014	0.9834	-0.4968
NTDOF	2.0037	1.7777	-3.1636
NVDA	1.0366	0.9134	-0.1144
SEGA	1.9203	1.5735	-2.8240
SONY	3.7875	3.5293	-13.8768

从以上指标，可以得出以下结论：

（1）所有样本的 R^2 均为负，说明按当前训练、测试集的划分及预处理方式，GPR 的预测均方误差通常高于用测试集均值做常数预测的基线。即，以模型当前的设置，未能提供在数值上显著改进的点预测。

（2）NVDA 在五支中表现最接近可接受水准（RMSE 最小、且 R^2 接近 0），表明模型对其年内走势的捕捉相对较好；MSFT 次之。NTDOF、SEGA 与 SONY 的误差明显较大，尤其 SONY 的 RMSE 与 R^2 指标指示模型在该股票预测上严重偏离真实数据。

（3）MAE 与 RMSE 的比较显示，MSFT、SEGA 等股票存在较大离群误差（RMSE 显著高于 MAE），意味着少数时间点的预测偏差特别严重。

3.2 预测曲线与真实数据的对比分析

结合测试集真实价格、预测均值曲线与 95%置信带的图像，对每支股票的均值预测与真实轨迹进行概括性分析。

（1）MSFT

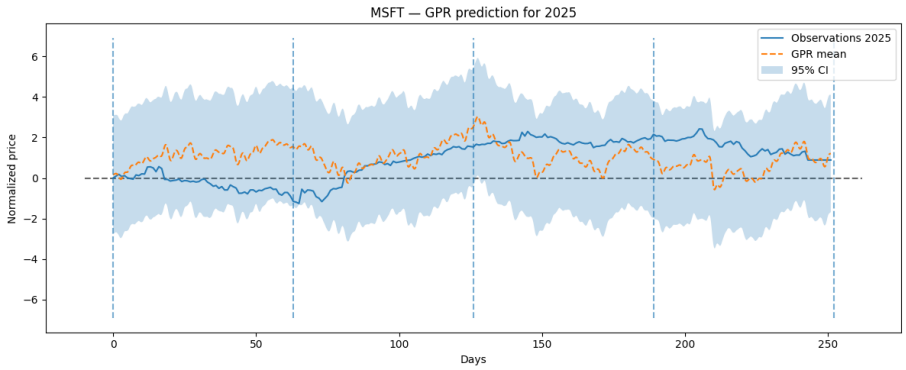

MSFT 的预测均值曲线总体较平滑，能在若干区间给出接近的上升、下降趋势，但在若干局部波动处与真实观测存在显著偏离，导致总体误差偏大。例如，在前 75 个交易日内，真实价格处于低位震荡，而预测均值却处于较高的水平；以及，第 150 天起，真实价格以较平滑的趋势保持在高位，而预测均值却表现出向零均值回归的波动态势。出现以上的结果，推测可能是由于模型对历史均值的“记忆”过强，导致在股票发生结构性变化时，预测结果明显滞后且保守，这也导致其拥有较大的 RMSE。

（2）NTDOF

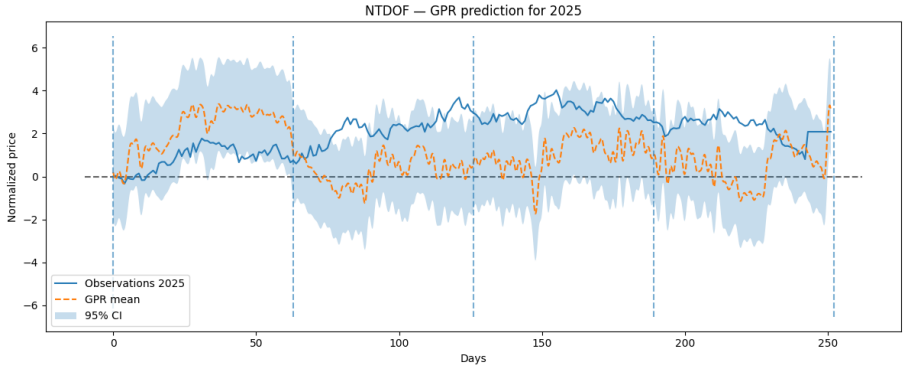

NTDOF 的预测曲线表现出极强周期性波动。在第 0 - 50 天，模型预测价格大幅上涨，但真实价格仅微幅波动；而在第 100 - 200 天，真实价格处于高位小幅波动时，预测均值却在 0 轴附近大幅震荡。真实数据与预测均值在多个阶段呈现出“反向走势”，说明基于过去周期的核函数推导在 2025 年的特定市场环境下可能失效；另一方面，由于训练数据的值在某一时间点存在断崖式下降，模型可能学习到这一特征、在后续的预测中偏好下降趋势的预测值。

（3）NVDA

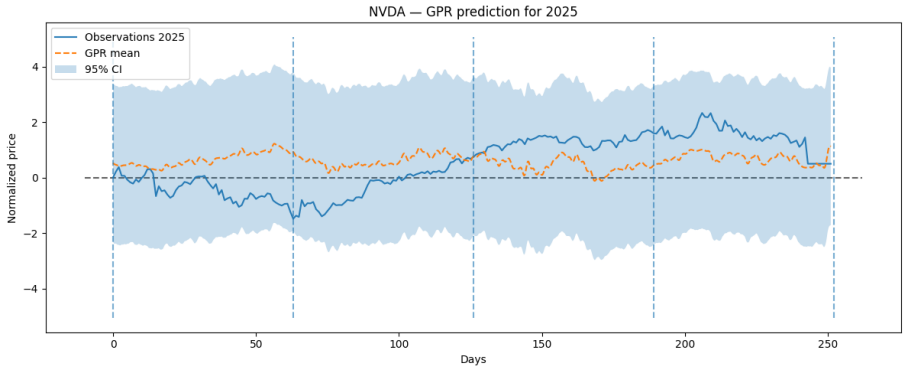

NVDA 的预测均值与观察值的整体趋势较为一致，特别是在中后段能较好跟踪价格的升降，相应的 RMSE 与 MAE 最小；这说明对于这支股票当前的表示与核结构，GPR 能较好地捕捉可重复的平滑成分。

（4）SEGA

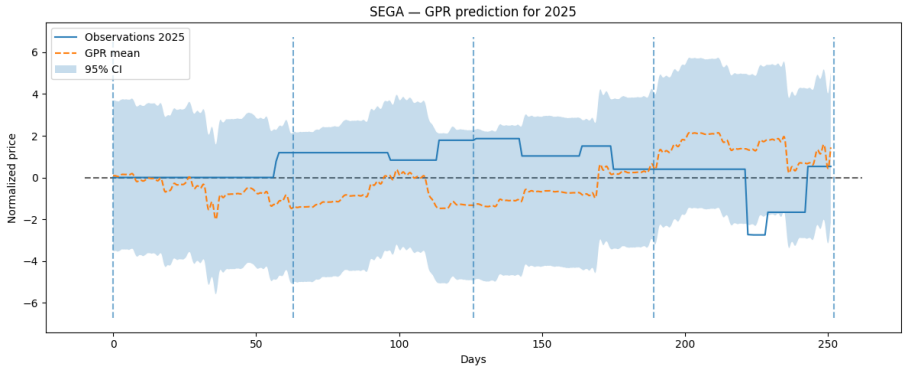

SEGA 的预测均值多为平滑水平段、且带有微小震荡，无法跟上真实轨迹中的若干变

动；置信带较宽，表明模型通过更高不确定性来补偿拟合失败。推测 GPR 模型基于 RBF 核的平滑特性，无法处理类似 SEGA 这种受离散事件驱动产生的阶跃式股价变动，导致两者在形态上完全无法匹配。

（5）SONY

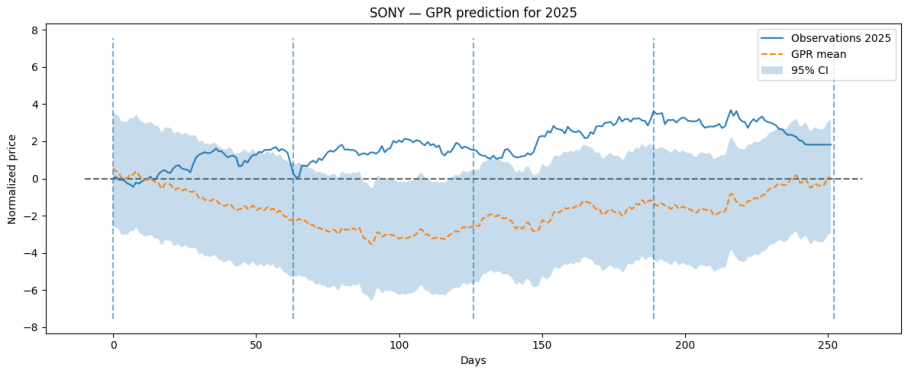

SONY 的预测均值与真实价格长期偏离且误差极大。整个 2025 年期间，SONY 的真实价格几乎全部运行在零轴上方，展现出极强的上涨趋势；反之，预测均值却自第 50 天起一路走低并长期处于负值区域。推测的具体原因在 3.3 节中给出。

3.3 核函数学习结果分析

以下是针对各支股票的核函数学习结果及相应的分析。

（1）MSFT

$$1.06^2 \cdot \mathrm{RBF}(l = 0.912) + 0.402^2 \cdot \mathrm{ExpSineSquared}(l = 1.06, p = 400) + \mathrm{White}(10^{-6})$$

RBF 与周期分量都有可观幅度，但噪声被优化到极小值，意味着模型将更多方差归因于信号而非噪声；周期周期性被学习到 p 的上界（400 天），暗示模型倾向于慢周期或过拟合年际趋势。

（2）NTDOF

$$1.15^2 \cdot \mathrm{RBF}(1.02) + 0.00316^2 \cdot \mathrm{ExpSineSquared}(0.0258, 248) + \mathrm{White}(7.6 \times 10^{-4})$$

周期分量振幅几乎为零，表示周期性不被模型采纳；噪声量级较小但非零，RBF 主导。模型在测试上表现差，可能因为价格突变、非平稳性难以由单一平滑核解释。

（3）NVIDIA

$$1.11^2 \cdot \mathrm{RBF}(0.892) + 0.00814^2 \cdot \mathrm{ExpSineSquared}(549, 64.7) + \mathrm{White}(10^{-6})$$

RBF 主导，周期分量幅度小，所学周期 64.7 天与设定的 252 天年周期差异较大，但其系数很小因此影响微弱。NVDA 的相对成功表明 RBF 捕捉到有用的平滑结构。

（4）SEGA

$$1.51^2 \cdot \mathrm{RBF}(1) + 0.319^2 \cdot \mathrm{ExpSineSquared}(l = 1.85, p = 400) + \mathrm{White}(10^{-6})$$

RBF 与周期同时有贡献，周期被学到上界，噪声项极小，模型倾向于把变化解释为可重复的慢变成分。

（5）SONY

$$1.02^2 \cdot \mathrm{RBF}(0.788) + 24.4^2 \cdot \mathrm{ExpSineSquared}(5.07{,}357) + \mathrm{White}(1.57 \times 10^{-6})$$

周期分量幅度巨大，表明优化过程将大量方差放在了周期模式上；但实际预测均值与观测严重偏离，说明该“学习到的周期”并非真实可泛化的周期，而更像是对训练数据中的结构性偏差或异常的过拟合。这也导致了模型对该股票 2025 年数据的预测表现不佳。

3.4 预测不确定性的评估与分析

GPR 的核心优势之一是输出预测均值之外的置信区间，置信带宽度的差异反映模型对不同股票及不同时间段信息量的判断。可以从图与核参数的分析中得出以下结论：

（1）对 SEGA，置信区间较宽，图中大部分真实点落在 95% 区间内，说明模型通过放宽不确定度承认其预测均值的不可靠性，同时也说明模型均值拥有较低的实用指引价值。

（2）对 MSFT、NTDOF 与 NVDA，置信区间相对中等或较窄，且 NVDA 的真实点更多落入置信区间附近，显示模型在这些样本上既给出明确均值又对不确定性有较佳估计。

（3）SONY 的情况较为极端。训练得到的周期核系数非常大，置信区间可能不稳定。图中可见在某些时间段，置信区间并不能有效覆盖观测序列的系统偏差，表明模型错误地把系统性偏差当作可再现的周期成分。

总体上，置信区间的校准性不足。尽管宽置信区间能覆盖实际观测，但若均值持续偏离且置信区间过宽，则对决策价值有限；相反，若置信区间过窄而观测频繁落外，则说明不确定性被低估。

4. 总结

本实验阐述了高斯随机过程回归（GPR）的基本定义，在学习 GPR 的基本知识的基础上，完成了对五支股票日收盘价的建模与预测。实验选取了 MSFT、NTDOF、NVDA、SEGA、SONY 五支具有不同波动特征的股票，利用 2016 年至 2024 年的历史数据作为训练集，对 2025 年的价格走势进行了预测。在模型构建方面，实验设计了由平方指数核（RBF）、周期核（ESS）和白噪声核（White Kernel）组成的复合核函数，旨在同时捕捉市场的长期趋势、周期性规律及随机噪声。通过对数据进行标准化、按年对齐及去基线处理，确保了模型对不同年份价格模式的敏感度。

从实验结果看，在当前预处理与单一价格特征下，GPR 在股票预测中能有效地提供预测不确定性、并在个别股票上对平滑成分建模有效，但整体预测性能受限于数据的非平稳

性和核函数的学习结果。学习结果揭示了两类问题：一类是模型把太多方差解释为确定性信号，另一类是周期分量有时被错误放大或缩小、导致均值预测失真。未来可以针对性地调整核结构、噪声建模与验证方式，以提高泛化能力，并使不确定性输出更具可用性。

5. 参考文献

[1] M.Ebden, " Gaussian Processes for Regression An Quick Introduction".

[2] H.M.Wallace, “Introduction to Gaussian Process Regression”

[3] M.T. Farrell, et al, “Gaussian Process Regression Models for Predicting Stock Trends”.

[4] Long-term Stock Market Forecasting using Gaussian Processes

[5] https://scikit-learn.org/stable/modules/generated/sklearn.gaussian_process.GaussianProcessRegressor.html

[6] https://github.com/gdroguski/GaussianProcesses/